

BigSolDB2.0:

- Se descargó la base de datos.
- Se filtraron solo los datos que tuvieran agua como solvente.
- Se hizo un algoritmo que solamente dejaba las mediciones más cercanas a 298K
- Se utilizó el script de ionizable_groups.ipynb para solamente dejar las moléculas que **no tuvieran grupos ionizables**, ya que se desconoce si el logS consiste en la solubilidad intrínseca.

SolCbio3database:

- Se buscaron todos los datos de logS, mp y logP en papers de solubilidades experimentales.
- Para los perfiles de solubilidad, solamente se dejó el dato de logS más bajo, el cual consistirá en su solubilidad intrínseca.

AqSolDB:

- Se filtraron solamente las moléculas no-ionizables (ya que son datos de solubilidad a pH = 7 y 300K). Entonces, solo las moléculas no-ionizables tendrán solubilidades aproximadamente iguales a las intrínsecas.

Unificación de los datasets:

- Se estandarizaron los SMILES de todos los datasets utilizando MolVS (<https://github.com/mcs07/MolVS/tree/master>) (<https://molvs.readthedocs.io/en/latest/index.html>)
- El script está en colab
- Se creó un script para colocar los SMILES nuevos de AqSolDB y BigSolDB a SolCbio3database. Se arrastraron los IDs, CAS, SMILES (con y sin estandarizar) y los valores de logS.
- Se utilizó la base de datos de logP de Kenneth para rellenar los valores de logP de las moléculas añadidas.
 - El script está en el colab.

Búsqueda de mps y logPs restantes:

- Se extrajeron un csv con todos los compuestos de PubChem que tienen reportados mp (~11000) y logP (~18000). Se verá cuáles compuestos que faltan de llenar se encuentran en esas bases de datos, y se buscarán.
- Después de esa búsqueda, los datos con logP o mp faltantes se borrarán.

Agregar CAS RNs faltantes:

- Se descargó un csv con los ~1millón de compuestos que tienen CAS registrados en pubchem.
- Se les estandarizaron los SMILES, y se revisó, si los smiles son iguales, que se agregue el CAS a ese compuesto.

Con todo esto, la base de datos pasó de 900 moléculas a 1355 con datos de logS, logP y punto de fusión.

Se repetirá el mismo procedimiento apenas tengamos la base de datos de Avdeef